TokenHSI/PUSH distillation

11/05 중간 보고

2026-11-05 · 이준형

요약

기존 Task 수행능력은 유지하지만, Push 성능이 크게 미달

기존 task 수행능력 보존

≤ 1.7%

teacher 대비 상대 하락 (제출 모델, B 11600 에폭). SIT 0.4%, CARRY 1.7%, CLIMB 0.2% 하락

PUSH 성공률은 아직 미달

3.42%

final (제출 모델, B 11600 에폭, ever 3.52%).

학습 진행

11.6k

제출 모델의 에폭 (12.2k에서 학습 멈춤). 매우매우 느리게 증가하는 중

학생 수치는 학습 중 평가(평가 seed 0)입니다. 제출 모델은 이 평가에서 PUSH final이 가장 높았던 체크포인트입니다.

실험 Setting

항목	설정
모델	TokenHSI transformer, 관측 397D. PUSH 토큰은 CARRY 토크나이저를 복사해 초기화
teacher 모델	공개 TokenHSI Stage1 체크포인트 (40k 에폭), teacher는 고정
학습 방식	PUSH 데이터는 PPO + AMP, 기존 task 데이터는 KL에서만 사용
학습 규모	PUSH 장면 2,048개(장면당 2명/상자 4개) + 기존 과제 환경 2,048개 = 6,144명이 동시에 학습. 그중 PUSH 학습 표본은 약 1/3(약 2,000명). 에폭당 32 step씩, 196,608 샘플
기존 과제 평가	원본 TokenHSI eval: 과제별 환경 512개 × 3 반복. 700 step 예열을 수행 후 평가(원본 코드에서 환경 생성 직후 첫 에피소드에 CLIMB가 붕괴. teacher도 동일)
PUSH 평가	PUSH 장면 512개 × 2명 = 1,024명이 첫 에피소드 1,200 step 수행, 끝날 때 상자 중심이 목표 3D 0.2 m 안이면 성공

실험

KD 방식 다섯 가지와, seed만 바꾼 B를 돌렸습니다

이름	KD 방식	계수	에폭	상태
A	나이브 (리드 기본)	0.001 고정	2,500	중단, KL이 약해 CARRY 성능이 급락
B	라그랑주, 목표 KL ε=1, seed 42	과제별 적응 (0.008~0.026)	12,200	멈춤 (제출 후보)
B(seed43)	B와 같음, 학습 seed만 43	과제별 적응	2,500+	진행 중
C	B + feature distillation	ε=1 + feature MSE 1.0	2,040	중단: PUSH 성능 정체
D	고정	0.0128 고정	4,000	중단: PUSH 성능 정체
E	라그랑주, ε=0.5	더 강하게 (0.026~0.039)	2,300	중단: GPU 부족

$$L = L(\text{PPO} + \text{AMP}) + \Sigma_k \lambda_k \cdot (n_k / n) \cdot KL_k(\text{teacher} \,\|\, \text{student})$$

$$\lambda_k \leftarrow 2\lambda_k \text{ if } KL_k > 1.5\varepsilon,\ \lambda_k \leftarrow \lambda_k / 2 \text{ if } KL_k < \varepsilon / 1.5$$

$k \in \{\text{SIT, CARRY, CLIMB}\}$, n_k = 과제 k의 KD 표본 수. 매 에폭 갱신, 시작값 0.001, 범위 $[10^{-4}, 10]$.

결과 1 · 중간 성적 (학습 진행 중)

기존 task 수행 능력은 잘 보존.. PUSH는 이제 막 오르는 중

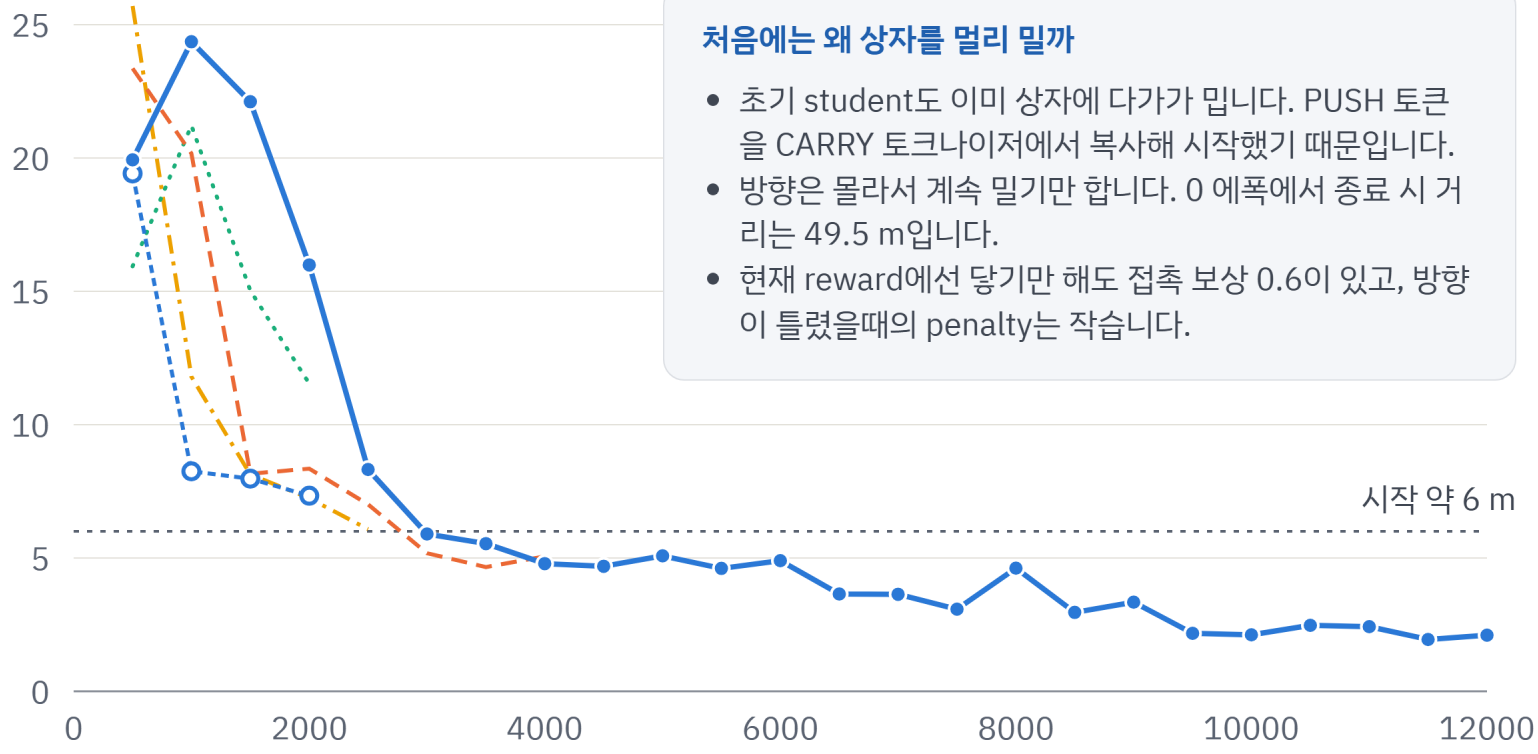
학습	에폭	PUSH final / ever	SIT / CARRY / CLIMB	기존 과제	종료 거리 (참고)
teacher			99.52 / 96.57 / 99.78	합격선 ×0.95	
A	2,500	0 / 0.20%	98.57 / 88.54 / 98.70	CARRY 미달	6.1 m
B (제출)	11,600	3.42 / 3.52%	99.09 / 94.92 / 99.61	합격	2.0 m
B(seed43)	2,000	0 / 0.20%	99.28 / 96.03 / 99.74	합격	7.3 m
C	2,000	0 / 0.10%	99.22 / 94.21 / 99.74	합격	8.5 m
D	4,000	0 / 0.10%	99.15 / 94.47 / 99.80	합격	5.1 m
E	2,000	0 / 0.29%	99.61 / 96.03 / 99.87	합격	11.5 m

제출 모델은 학습 중 평가에서 PUSH final이 가장 높았던 B 11,600 에폭입니다. 9,800~12,100 에폭에서 Push final 평균은 약 1.9%로, 7,000~8,900(약 0.8%)의 두 배 이상입니다. 즉 느리지만, 매우매우 천천히 증가는 하고 있습니다. 목표인 final 85% 초과는 현재 구조라는 어려워 보입니다.

결과 2 · PUSH 학습 곡선

올바른 학습 방향은 배웠지만... 너무 느린 성능 증가

종료 시 상자–목표 거리 (중앙값, m) · 참고 지표



처음에는 왜 상자를 멀리 밀까

- 초기 student도 이미 상자에 다가가 밉니다. PUSH 토큰을 CARRY 토크나이저에서 복사해 시작했기 때문입니다.
- 방향은 몰라서 계속 밀기만 합니다. 0 에폭에서 종료 시 거리는 49.5 m입니다.
- 현재 reward에선 닿기만 해도 접촉 보상 0.6이 있고, 방향이 틀렸을때의 penalty는 작습니다.

B 라그랑주 ε=1
12000 에폭 2.1 m

B(seed43)
2000 에폭 7.3 m

D 고정 0.0128
4000 에폭 5.1 m

E 라그랑주 ε=0.5
2000 에폭 11.5 m

A 나이브 0.001
2500 에폭 6.1 m

500 에폭마다 전체 평가, seed 0, 1,024명. 성공 판정은 final(종료 시 0.2 m 안)로만 합니다.
다만 현재 reward, lr, scheduler로는 26K 모델과 동일한 에폭에서 성능 비교는 어려울 거 같습니다.

원인 분석 1

목표 쪽으로 미는 보상 신호가 매우 약합니다

접촉 보상

0.6 / step

올바른 면에 닿기만 하면 바로 최대치입니다.

목표 방향 보상의 기울기

+0.005 / step

6 m 지점에서 1 m 가까워질 때. 접촉 보상의 약 1/100입니다.

1단계

상자까지 가서 밀기(접촉)

2단계 · 20 m 이상

엉뚱한 방향으로 계속 밀기

3단계 · 지금 B가 학습 중인 단계

목표 쪽 (약 2 m)으로 밀기

4단계 · 성공

0.2 m 안에 놓기

원인 분석 2 · 학습 단계별 그래디언트 진단

병목은 KD가 아니라, PUSH 학습 신호에 존재하는 큰 noise

1단계

상자까지 가서 밀기

2단계 · B 500, 1500 에폭

엉뚱한 방향으로 계속 밀기

PUSH 신호 : 잡음

1 : 6~7

KD가 PUSH 진행에 준 영향

-0.3% / +1.7%

3단계 · B 7600 에폭

목표 쪽으로 밀기

PUSH 신호 : 잡음

1 : 10

KD가 PUSH 진행에 준 영향

-0.3%

4단계 · 성공

0.2 m 안에 세우기

B가 9,500 에폭 이후 Push final이 2%대로 들어서기 시작했습니다. 12K까지 2~3%대에 머물러 있습니다.

처음에는 KD가 학습을 보수적으로 수행하게끔 해 push 성능이 천천히 증가한다고 생각했으나, 그래디언트 진단 결과, KD가 PUSH 진행 속도에 주는 영향은 ±2% 안이라 KD 계수 튜닝으로 PUSH가 빨라질 여지는 거의 없습니다. 목표 쪽으로 밀어야 하는 3단계에서는 오히려 1,2단계보다 학습 noise가 뚜렷하게 많아져 PUSH 신호가 더 약해집니다. 이것이 현재 학습 저하의 원인이라고 생각됩니다(결과2에서 목표거리가 매우 느리게 감소하는 현상이 뚜렷). Readme.m에 제안하는 개선 방향을 기록하였습니다.